

AS in ML
models ↓

↓

Визуал и / или ли?

- Оптимизация EM на графах
- Bootstrap: способ пер-их довер. инт

EM algorithm u kl-gubereuyush.

zagora: $\max_{\theta} \ln p(x|\theta)$

} zamenchit na EM-algoritm

Init. $\theta_{old} := \theta_{init}$

[zamennit]
na nov.

E-step. najti $p(z|x, \theta)$

guyat
naso

$$Q(\theta, \theta_{old}) = E \left[\ln(p(x, z | \theta)) \mid x, \theta_{old} \right]$$

M-step. $\max_{\theta} Q(\theta, \theta_{old}) \rightarrow \theta_{new}$

//

$\theta_{old} := \theta_{new}$

Хотим получить максимум $p(z|x, \theta)$
или логарифм.

Схемами

θ - изв. параметр	
z - скрытая переменная	$x = (x_1 \dots x_n)$
вектор z (клетки)	$z = (z_1 \dots z_n)$

$$KL(q \| p_{z|x, \theta}) = (E(q \| p_{z|x, \theta}) - H(q))$$

распределение

хотим найти минимизацию

$$0 \leq KL(a \| b) = (E(a \| b) - H(a))$$

используем распределение

распределение, которое максимизирует логарифмическую вероятность.

среднее значение и дисперсия (в среднем)

II

$$\text{найдем: } \min_q KL(q \| p_{z|x, \theta}) \Rightarrow q^* = p_{z|x, \theta}$$

не работает, т.к. чтобы вывести KL надо уже знать $p_{z|x, \theta}$.

Лайтхаус:

$$\underbrace{\ln p(x|\theta)}_{\text{не зависит от } q} = \underbrace{KL(q \| p_{z|x, \theta})}_0 + LB(q, \theta)$$

Е-макс: $LB(q, \theta) \rightarrow \max$ $\left\{ \begin{array}{l} q^* = p_{z|x, \theta} \end{array} \right.$

Цель: для каждого LB не нужно знать $p_{z|x, \theta}$

$$\begin{aligned}
 LB(q, \theta) &= \ln p(x|\theta) - KL(q \| p_{z|x, \theta}) = \quad [\text{нас}] \\
 &= \ln p(x|\theta) - \left[CE(q \| p_{z|x, \theta}) - H(q) \right] = \\
 &= \ln p(x|\theta) - \left[\underbrace{\int q(z) \cdot \ln p(z|x, \theta) dz}_{\substack{\uparrow \text{нас-ное} \\ \uparrow \text{распр-е} \text{ } q \text{ на распр-е } p_{z|x, \theta}}} + \int q(z) \ln q(z) dz \right]
 \end{aligned}$$

$$\begin{aligned}
 [\text{нас}] \quad CE(q \| p) &= \int q(z) \log_2 p(z) dz = - \int q(z) \log_2 p(z) dz \quad \leftarrow \\
 [\text{нас}] \quad &= - \int q(z) \ln p(z) dz \cdot \left[\frac{\text{нас}}{\ln 2} \right] \quad \leftarrow
 \end{aligned}$$

$$= \int q(z) \ln p(z|\theta) dz + \int q(z) \ln p(z|x, \theta) dz - \int q(z) \ln q(z) dz$$

$$LB(q, \theta) = \int q(z) \cdot \ln \frac{p(x|\theta) \cdot p(z|x, \theta)}{q(z)} dz =$$

$$LB(q, \theta) = \int q(z) \cdot \ln \frac{p(x, z|\theta)}{q(z)} dz$$

$$\Downarrow \quad \left[\text{выражение } p(z|x, \theta) \right]$$

EM - алгоритм

Init: $\theta_{old} := \theta_{init}$

E-шаг: $\max_q LB(q, \theta_{old})$

$$\left\{ \begin{array}{l} q^{new} = p(z|x, \theta) \end{array} \right\}$$

M-шаг:

$\max_{\theta} LB(q^{new}, \theta)$

$\theta_{old} := \theta_{new}$

$$\ell(x|\theta_{old}) \stackrel{E\text{-max}}{=} LB(q^{new}, \theta_{old}) \stackrel{M\text{-max}}{\leq} \underbrace{LB(q^{new}, \theta_{new})}_{\leq} \leq$$

$$q^{new} = p(z|x, \theta_{old}) \leq \ell(x|\theta_{new})$$

$KL=0$ $KL \geq 0$

$$\ell(x|\theta_{new}) \geq \ell(x|\theta_{old}) \quad \Downarrow$$

$$\begin{array}{ccc} E \text{ max over } p(z|x, \theta) & \rightarrow & E \text{ max over } q \\ M \text{ max over } \theta & & M \text{ max over } \theta \end{array}$$

$$\max_{\theta} Q(\theta, \theta_{old}) \leadsto \max_{\theta} LB(q^{new}, \theta)$$

Yup! gotta make substitutions.

Бутстреп (Bootstrap)

- метод построения дов-х интервалов.

θ - неув. пар-р

x - выборка.

$\hat{\theta}$ - оценка неув-го θ

$$\hat{\theta} = h(y)$$

+ алгоритм $\hat{\theta}$ не важен

- алгоритм асимпт.

для непер-ич
бутстреп

$x \sim F$ F неув

параметр-ич
бутстреп.

$x \sim F_{\theta}$ F_{θ} известна
с жено всю до θ

reverse percentile bootstrap

\rightarrow t-bootstrap


$$x_1, \dots, x_n \Rightarrow \hat{\theta} = h(y)$$

$$\hat{\delta} = \hat{\theta} - \theta$$

\uparrow не знаем!

Еще бы

у меня была выборка $\hat{\delta}$



$$\hat{\delta}_L \leq \hat{\theta} - \theta \leq \hat{\delta}_R \quad 95\%$$

$$-\hat{\delta}_R \leq \theta - \hat{\theta} \leq -\hat{\delta}_L$$

$$\Rightarrow \theta \in [\hat{\theta} - \hat{\delta}_R; \hat{\theta} - \hat{\delta}_L]$$

мы!

Результат:

$$x_1, \dots, x_n \rightarrow \hat{\theta} = h(x_1, \dots, x_n)$$

$$\hat{\delta} = \hat{\theta} - \theta$$

\uparrow \uparrow
 априорная θ \leftarrow bootstrap ke жасау

$$\begin{aligned} &\mu = E(x_i) \\ &x_i \sim \text{i.i.d} \quad E(x_i) < \infty \end{aligned}$$

~~$$x_i \sim N(\mu, 1)$$~~


Бутстрап-выборка

$$x_1^*, \dots, x_n^* \rightarrow \hat{\theta}^* = h(x_1^*, \dots, x_n^*)$$

$\times \underline{10000}$ жол

$$\hat{\delta}^* = \hat{\theta}^* - \hat{\theta} \leftarrow \text{10000 жол}$$

x x^* x^* x^*
 $\begin{bmatrix} 5 \\ 6 \\ 2 \end{bmatrix}$ $\begin{bmatrix} 6 \\ 6 \\ 2 \end{bmatrix}$ $\begin{bmatrix} 5 \\ 5 \\ 5 \end{bmatrix}$ \dots $\begin{bmatrix} 6 \\ 2 \\ 2 \end{bmatrix}$
 $\underbrace{\hspace{10em}}_{10000 \text{ жол}}$



$$CI_{\text{Boot}} = \left[\hat{\theta} - \hat{\delta}_{R^*} : \hat{\theta} - \hat{\delta}_{L^*} \right]$$

Нормальное распределение:

$$x_i \sim F \leftarrow \text{норм. р. распр}$$

$$F^* \leftarrow \text{boot. р. распр-ия}$$

$$n - \text{велико} \Rightarrow \underline{F^* \approx F} \Rightarrow \text{Law}(\hat{\delta}^*) \approx \text{Law}(\hat{\delta})$$

t-bootstrap.

если теоремы,
к-рые в идеальных
условиях или
или $n \gg 0$

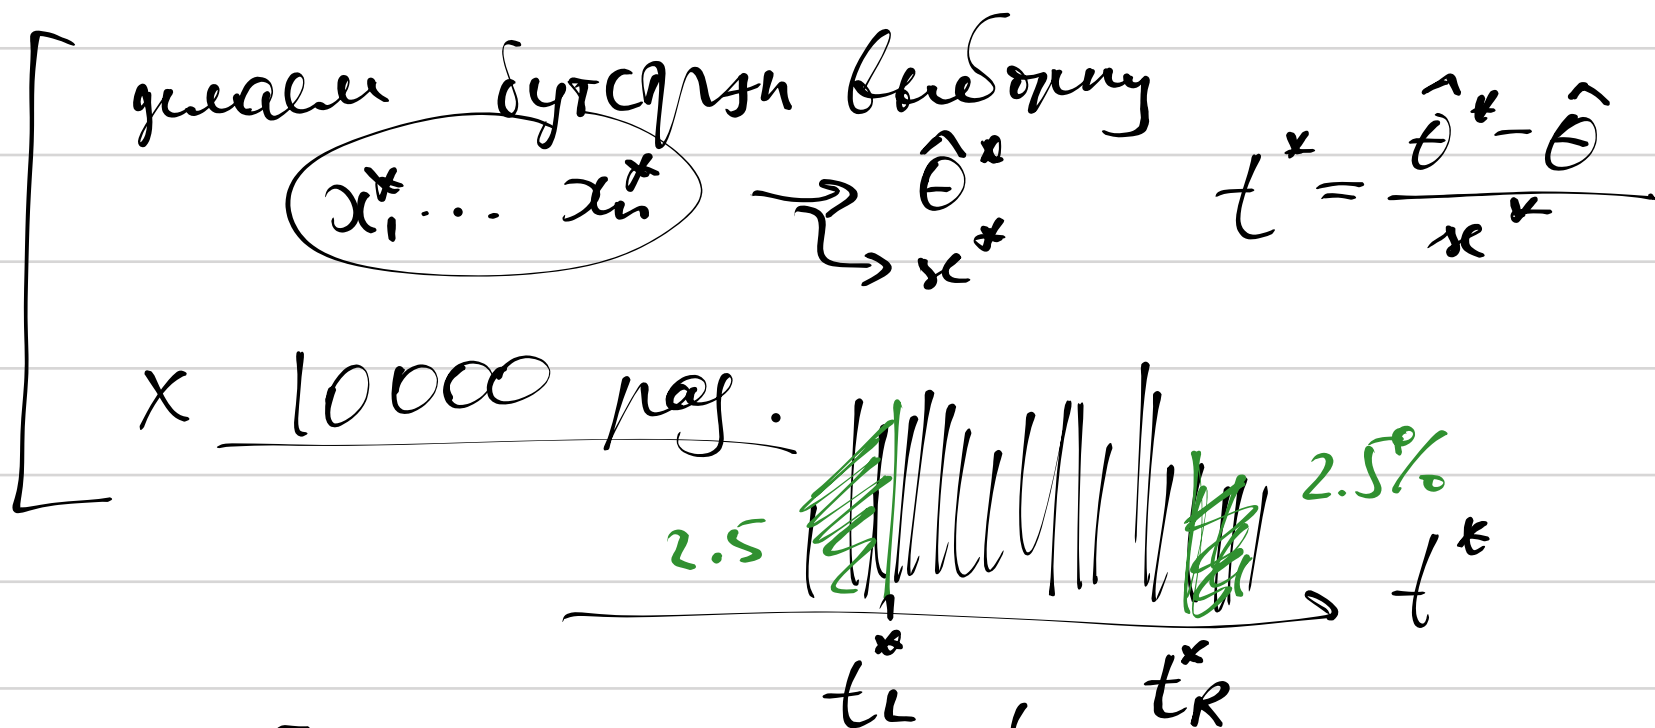
$$\frac{\hat{\theta} - \theta}{se(\hat{\theta})} \rightarrow N(0,1)$$

Если $x_1, \dots, x_n \sim N(\mu, \sigma^2)$ независимы

$$\hat{\mu} = \bar{y} \quad \text{то} \quad \frac{\bar{y} - \mu}{se(\bar{y})} \sim t_{n-1}$$
$$se(\bar{y}) = \sqrt{\frac{\sum (y_i - \bar{y})^2}{n-1}} = se$$

t-bootstrap:

x_1, \dots, x_n



идеальный:

$$CI = [\hat{\theta} - t_R \cdot se(\hat{\theta}); \hat{\theta} - t_L \cdot se(\hat{\theta})]$$

t-бутстреп

$$CI_{boot} = [\hat{\theta} - t_R^* \cdot se(\hat{\theta}); \hat{\theta} - t_L^* \cdot se(\hat{\theta})]$$

парам. бутстреп:

$$x_1^*, \dots, x_n^* \sim y \quad F_{\hat{\theta}}$$